



Hochschule **RheinMain**  
Fachbereich Design Informatik Medien  
Studiengang Medieninformatik

## Abschlussarbeit

zur Erlangung des akademischen Grades

Master of Science

---

# **Data Mining komplexer Datenstrukturen aus PDF-Dokumenten**

---

Vorgelegt von Deniz Aydar  
am 25. Juli 2022  
Referent Prof. Dr. Dirk Krechel  
Korreferent Prof. Dr. Philipp Schaible

## **Erklärung gemäß ABPO**

Ich erkläre hiermit, dass ich

- die vorliegende Abschlussarbeit selbstständig angefertigt,
- keine anderen als die angegebenen Quellen benutzt,
- die wörtlich oder dem Inhalt nach aus fremden Arbeiten entnommenen Stellen, bildlichen Darstellungen und dergleichen als solche genau kenntlich gemacht und
- keine unerlaubte fremde Hilfe in Anspruch genommen habe.

Wiesbaden, 25. Juli 2022

---

Deniz Aydar

## **Erklärung zur Verwendung der Masterthesis**

Hiermit erkläre ich mein Einverständnis mit den im folgenden aufgeführten Verbreitungsformen dieser Abschlussarbeit:

<b>Verbreitungsform</b>	<b>Ja</b>	<b>Nein</b>
Einstellung der Arbeit in die Hochschulbibliothek mit Datenträger		×
Einstellung der Arbeit in die Hochschulbibliothek ohne Datenträger		×
Veröffentlichung des Titels der Arbeit im Internet	×	
Veröffentlichung der Arbeit im Internet		×

Wiesbaden, 25. Juli 2022

---

Deniz Aydar

## **Zusammenfassung**

PDF-Dokumente besitzen viele Informationen, aus denen sich neue Daten generieren lassen können. Doch das Extrahieren von solchen Daten ist heutzutage immer noch mit Hürden verbunden. Dies gilt auch für die Dokumente, die in den Prozessen von Autohäusern und deren Kfz-Werkstätten verwendet und anschließend gelagert werden. Um die Frage zu beantworten, inwiefern neue Daten aus dieser Art von Dokumenten verarbeitet werden können, wird im Rahmen dieser Arbeit ein System konzipiert und entwickelt, welches es ermöglichen soll, weiteres Wissen zu gestalten beziehungsweise zu generieren. Dieses System will dabei zwei verschiedene Ansätze aus der künstlichen Intelligenz nutzen, um einen automatisierten Lösungsweg zu kreieren, und eine grafische Schnittstelle für die Möglichkeit der menschlichen Nutzung anbieten.

# Inhaltsverzeichnis

<b>1 Einleitung</b>	<b>3</b>
1.1 Zielsetzung . . . . .	4
1.2 Ablauf . . . . .	6
<b>2 Hintergrund</b>	<b>8</b>
2.1 Kontext . . . . .	8
2.2 Analyse . . . . .	9
2.2.1 Extraktionsbibliotheken . . . . .	10
2.2.2 Dokumentarten . . . . .	12
2.2.3 Frameworks . . . . .	17
<b>3 Konzeption und Umsetzung</b>	<b>20</b>
3.1 Aufbau . . . . .	20
3.2 Symbolische KI . . . . .	22
3.2.1 Extraktionsvorgang . . . . .	23
3.2.2 Webserver . . . . .	25
3.2.3 Syntax und Grammatik der Fakten und Regeln . . . . .	25
3.2.4 Regelmaschine . . . . .	29
3.3 Entwicklungsumgebung . . . . .	31
3.3.1 Editor . . . . .	31
3.3.2 Dokumentenanzeige . . . . .	31
3.3.3 Output . . . . .	31
3.4 Machine Learning . . . . .	31

3.4.1 Webserver . . . . .	31
3.4.2 Pipeline . . . . .	31
<b>4 Ergebnisse</b>	<b>32</b>
4.1 Testing . . . . .	32
<b>5 Konklusion und Ausblick</b>	<b>33</b>

# **Kapitel 1**

## **Einleitung**

„Digitalisierung im Alltag voranbringen“ – Das war einer der Wahlslogans während der Bundestagswahl 2021. Gemeint war damit die Forderung nach einer zunehmende Digitalisierung im privaten Alltag vieler Bürger:innen, aber auch in der Wirtschaft machte sich wachsend der Wunsch nach mehr digitalen Alternativen breit (vgl. Bundesregierung 2021). Dieser Wunsch beinhaltete vor allem einen Wechsel von gängigen Papierformen verschiedenster Dokumente hin zu denselben in digitaler Ausprägung.

Genau jenes Bedürfnis nach Digitalisierung betrifft auch die vielen Arbeitnehmer:innen und Händler:innen in Autohäusern und deren Kfz-Werkstätten, die durch ihre beruflichen Tätigkeiten mit einer Vielzahl an Unterlagen, Dokumenten oder Belegen arbeiten müssen. Unter dieser Vielzahl fallen Dokumente wie Werkstatt-, Kauf- und Mietverträge sowie Rechnungen oder Diagnoseberichte.

Jene Beschäftigte in einigen Autohäusern und deren Kfz-Werkstätten sind Kund:innen bei ilexius GmbH. Ilexius bietet Enterprise-Resource-Planning (ERP) Systeme an, mit Hilfe derer Arbeitsaufträge und Arbeitsschritte innerhalb des täglichen Arbeitsprozesses in Autohäusern und deren Werkstätten durch Digitalisierung vereinfacht werden. In Kooperation von ilexius GmbH werde ich daher die Problematik meiner Thesis, die ich im folgenden noch genauer beschreiben werde, lösen und in die Tat umsetzen.

Durch eine Digitalisierung jener Dokumente eröffnen sich Vorteile wie bessere Zugänglichkeit, größere Langlebigkeit und vor allem eine angepasste und leichtere Nutzung, die zu einer höheren Effektivität innerhalb täglicher Arbeitsschritte führt. Durch bisherige erste Schritte der Digitalisierung sind diese benötigten Dokumente bereits elektronisch aufgearbeitet und den Beschäftigten in Autohäusern und deren Kfz-Werkstätten zur Verfügung gestellt worden.

Die Folge dessen ist, dass alle Dokumente standardisiert sind und dadurch die in den Dokumenten beinhalteten Informationen neu verarbeitet werden können. Eine Extraktion der Daten der einzelnen Dokumente ist jedoch nur eingeschränkt möglich, da die Struktur im gängigen Gebrauch im Dateiformat Portable Document Format (PDF) festgelegt ist.

Jene Limitierung der Datenextraktion wirkt sich gleichermaßen auf die Dealer-Management-Systeme (DMS), mit solchen die Mitarbeiter:innen ihre Prozesse abwickeln, aus. Der daraus resultierende Arbeitsaufwand, welcher dabei entsteht, um die Daten wiederverwendbar zu konstruieren, ist derzeit enorm.

## 1.1 Zielsetzung

Aus diesem Grund möchte ich innerhalb dieser Master-Thesis ein System entwickeln, das genau jene Problematik erleichtert und löst. Innerhalb üblicher Methoden werden heutzutage die Daten zunächst über eine grafische Anzeige mithilfe einer bereits existierenden Benutzeranwendung via gängiges Kopieren und Einfügen entnommen. Dieser Schritt funktioniert zwar im Regelfall, ist jedoch oftmals stark fehleranfällig und kann lückenhaft sein.

In so einem Fall muss das Einfügen und Kopieren manuell durchgeführt werden, was bei einer riesigen Menge an Dokumenten zu einer monotonen Arbeit für die Händler der Autohäuser führt. Andernfalls können die Daten eigenhändig abgeschrieben werden – jener Vorgang benötigt jedoch viele Ressourcen. Eher geeignet ist es, einen Datenkonverter für die PDF Dateien zu nutzen, um so die Dokumente beispielsweise in Bilder umzuwandeln, wodurch die Daten zugänglicher sind, aber immer noch verarbeitet werden müssen. Die letztgenannte Möglichkeit wirkt allerdings eher wie eine Übergangslösung als eine professionelle endgültige Durchführung.

Aufgrund dieser bisherigen teils aufwendigen und mit Fehlern verbundenen Möglichkeiten möchte ich mich in meiner Thesis von diesen Optionen abwenden und das Data-Mining nutzen. Das Data-Mining soll eine Automatisierung unterstützen, mit der Daten aus dem PDF-Dokument extrahiert werden. Allein über das Data-Mining ist es möglich, Inhalte zu extrahieren und für andere Systeme bereit zu stellen.

Der Unterschied zwischen meiner Verwendung des Data-Minings und zum gängigen Data-Mining liegt dabei in den Einschränkungen des Dateiformats: der Quelltext einer solchen Datei stellt erstens keine klare Hierarchie der Daten dar und zweitens besitzt es durch das Fehlen von Markierungen keine Informationen darüber, was die Daten an sich darstellen sollen [21].

Mit Hilfe dieser Technik des Data-Minings soll es ermöglicht werden, aktuelle Prozesse detaillierter zu steuern und zu überwachen. Des Weiteren können unter anderem Abgleiche von Rechnungen mit dem System durchgeführt werden und weitere Datenanalysen und Reporting kreiert werden. Mit dem derzeitigen Stand der Datenextraktion können jedoch lediglich Agierende aus dem technischen Bereich arbeiten, da allein sie das dafür technisch notwendige Know-how besitzen. Die Technologien hierfür benutzen unterschiedliche Ansätze und müssen daher zunächst für diesen Fall ausgewählt werden.

Damit jedoch auch für Agierende innerhalb des technischen Bereichs die Nutzung nicht zu abstrakt bleibt, soll durch die Entwicklung eines Systems der Zugriff greifbarer gestaltet werden, welches wiederum allein durch eine benutzerfreundliche Anwendung ermöglicht wird. Die Benutzer:innen sollen eine Möglichkeit bekommen und über eine Eingabe der Steuerung bestimmten können, welche Informationen extrahiert werden sollen.

Darüber hinaus muss eine Automatisierung vorhanden sein, um auch eine große Datenmenge verarbeiten zu können; zudem sollen die Vorgänge eine niedrigere Fehlerquote aufzeigen. Die Prozesse müssen außerdem während des gesamten Ablaufs über eine Steuerung und Regelung kontrollierbar sein. Solche Prozesse können zum Beispiel über Regeln festgelegt beziehungsweise gesteuert werden, die hingehen bei einer Erfüllung weitere Aktionen oder Regeln auslösen können.

Diese im vorherigen genannten Absatz beschriebene Eigenschaft kann durch eine symbolische künstlichen Intelligenz (KI) abgedeckt werden, welche eine vorgegebene Verarbeitung zulässt. Hiermit bezeichnet man einen altmodischen Ansatz der KI, bei der über das Festlegen von Symbolen menschliches Wissen in einer Logik gehalten wird und diese benutzt wird um weiteres Wissen sodann zu generieren [20]. Durch eine Parametrisierung einer solchen KI kann dann die Unschärfe der ausgewählten Daten festgelegt werden, damit eine Feineinstellung erfolgen kann. Das heißt, die Benutzer:innen eines solchen Systems soll sich beginnend von groben Definitionen für die Verarbeitung zu einer detaillierten und angepassteren Definition über Feedback des Systems hinarbeiten.

Mit Hilfe dieser Annäherung an Definitionen und Regeln kann so für eine bessere Erfolgsquote gesorgt werden. Zudem kann der Ansatz des Machine Learnings (ML), mit jenem erfolgreiche Verarbeitungen einem System antrainiert werden, weitere Dokumente aus Daten extrahieren. Hierbei ist noch offen, welcher Typ des Machine Learnings sich für diesen Fall am optimalsten eignet.

Beide Ansätze – der der symbolischen KI und der des Machine Learnings – bieten als Option die Entwicklung einer grafischen interaktiven Entwicklungs-umgebung (IDE) an. Die IDE soll das Festlegen von Definitionen und Regeln

erlauben, mit welchen die Dokumente verarbeitet werden können. Außerdem soll diese Oberfläche verschiedene Funktionalitäten offerieren und auch Feedback sowohl bei einem problemlosen Lauf, als auch bei einem fehlerhaften Lauf, zurückgeben.

Des Weiteren soll es das System ermöglichen, Änderungen der Definitionen anzumerken und Unterschiede zu erstellen. Mit dieser Funktion sollen auch bisherige Ergebnisse angezeigt werden. Die Festlegung von Definitionen und Regeln soll außerdem durch eine Ansicht der Dokumente unterstützt werden. Insgesamt wird das System die zwei Ansätze als Subsysteme aufteilen um die Umsetzung zu modularisieren und einen Vergleich zu ermöglichen.

## 1.2 Ablauf

Um genau dieses optimale System für das beschriebene Szenario entwickeln zu können, werde ich in dieser Arbeit wie folgt vorgehen:

Für eine vollständige Auseinandersetzung soll eine weitere Analyse stattfinden, damit die vorhandenen Grundlagen für den Anwendungsfall, um den es in der Arbeit geht, evaluiert werden können. Das heißt, es werden mit Hilfe der Funktionalitäten der Bibliotheken Ergebnisse auf Basis der Datensätze erzeugt, um die Erfolgsquoten zu überprüfen. Diese werden dann verglichen und ausgewertet. Parallel dazu soll die Umgebung für die Entwicklung eingerichtet werden, mit der die Implementierung der Systeme stattfinden soll.

Danach widme ich mich der Konzeption und der Entwicklung des Systems. Diese beginnt mit der symbolischen KI als ein Subsystem des gesamten Projekts, durch selbige ein direkterer Ansatz ermöglicht wird. Die Entwicklung hierbei wird im Wasserfall-Ansatz, einem Ansatz bei der phasenweise die Eigenschaften einer solchen KI umgesetzt werden, um eine Grundlage für die nächste Komponente zur Verfügung zu stellen.

Bei dieser Komponente handelt es sich um die interaktive Entwicklungsumgebung, die den Zugang für die Benutzer:innen zum System darstellt. Deswegen folgt im nächsten Schritt die Konzeptionierung und Entwicklung der interaktiven Entwicklungsumgebung, welche sich während der Entwicklung der symbolischen KI parallelisieren lässt. Sobald das Gerüst der Benutzeroberfläche fertiggestellt ist, möchte ich dies mit der symbolischen KI verbinden.

Als Gegenstück wird sich dann mit dem Machine Learning Ansatz und dem dazugehörigen Subsystem, bei der gleichermaßen eine Konzeptionierung und Entwicklung stattfindet, gewidmet. Hier wird das bisherige Gesamtkonstrukt

in einem iterativen Ansatz umgesetzt, sodass der Hauptteil so früh wie möglich verfügbar ist, damit das Training des ML-Systems durch die Dokumente auch zeitnah starten kann. Auf das Auswerten dieses Subsystems folgt eine Anpassung dessen. Die Komponenten der symbolischen KI und des Machine Learnings erlauben damit einen Vergleich zwischen zwei verschiedene Ansätze aus der Künstlichen Intelligenz.

Danach wird das Software Testing für die beiden Subsysteme eingeführt. Mit Unit Testing, Integration Testing und Functional Testing wird das erfolgreiche Ausführen gewisser Eigenschaften abgedeckt. Dies dient wiederum als Grundlage dafür, die Continuous Integration (CI) für das System einzuführen, mit dieser eine sichere und konsistente Entwicklung nach dem Prototyping angeboten wird.

Wenn hierauf die Systeme gegeben sind, kann das grafische Tool weiter angepasst werden, welches sich dann mit den Systemen verbinden soll, um infolgedessen die Ausführbarkeit der Funktionalität überprüfen zu können. Um ein gemeinsames System zu ermöglichen, welches dann gegebenenfalls weitere Testschritte bedarf, werden anschließend die Komponenten zusammengeführt. Sobald jenes eine erfolgreiche Form annimmt, wird der Teil der Continuous Integration mit einbezogen, mit jener das System einen Zustand der Instandhaltung annehmen kann. Über Testing sollen so mögliche Fehlerquellen entdeckt werden, bevor diese überhaupt auftreten können.

Unter die Zielsetzung für meine beiden eben genannten Ansätze fallen die Kundendaten mit den Eigenschaften wie Name, Firma, Adresse und Kundennummer. Zu Eigenschaften der Fahrzeugdaten zählen Angaben der Fahrgestellnummer, Modell, Farbe, Motor, Erstzulassung, Letzter/nächster Service und TÜV sowie die Abrechnungsdaten wie die Jobs mit den dazugehörigen Arbeitspositionen, der Reparaturteile, den Preisen etc.

Dazu stehen als weitere Grundlage mehr als 10.000 annotierte unterschiedliche Dokumente mit genau den Daten, die extrahiert werden sollen, als Datenbank zur Verfügung. In Zukunft sollen für das Mengengerüst mehr als 100.000 Dokumente pro Jahr bearbeitet werden. Hierbei ist es aber auch möglich, aus den bereits bestehenden Daten einen Pool für den Lernprozess bzw. für die Verifikation zu bilden.

Zum Schluss werde ich die Ergebnisse des gesamten Systems betrachten und einen Ausblick zu der Thematik geben. Aus Datenschutzgründen werde ich in meiner Arbeit persönliche Informationen in den gezeigten Dokumenten anonymisieren und verpixeln.

# **Kapitel 2**

## **Hintergrund**

Um die Problematik detaillierter darzustellen und um eine Übersicht zu ermöglichen, wird in diesem Kapitel der Rahmen der Problematik aus technischer Sicht genauer dargestellt. Hierbei werden die möglichen Technologien abgewogen und evaluiert. Zunächst jedoch wird der Kontext ausführlicher erklärt.

### **2.1 Kontext**

Im Automobilbereich wird der Verkauf von Kraftfahrzeugen in zwei Segmente aufgeteilt: dem Sales-Bereich, bei dem es sich um den Verkauf von Neu- und Gebrauchtwagen handelt und dem After-Sales-Bereich, bei jenem eine Bindung zum Kunden über den Verkauf von Verschleiß- und Ersatzteilen geschaffen wird. [40] Diese Aufteilung der Segmente wird ebenfalls von den Autohäusern angewendet, zugleich werden für diese Aufteilung jeweils gängige Abläufe als Prozesse benutzt.

Für den After-Sales-Bereich bietet ilexius GmbH zwei Arten von ERP-Systeme an. Die erste Art ist das von der Automobilmarke Jaguar Land Rover finanzierte *vTab*, welches eine Plattform für elektronische Fahrzeugkontrollen und ein Backend für Jaguar Land Rover Mitarbeiter:innen, mit dem die Autohäuser bewertet werden können, anbietet. Die zweite Art mit dem Namen *ATT* ist eine Plattform. Mit derjenigen können Autohäuser ihre Arbeitsprozesse in Schrift, Sprache und Bild dokumentieren. Die Dokumentation erfolgt mittels mobiler Endgeräte und werden an das ERP-System weitergeleitet, sodass die Dokumentation archiviert werden kann.

Die ERP-Systeme, die bereits im Kapitel 1.1 beschrieben worden sind, unterstützen damit die Kunden:innen von ilexius GmbH in den Autohäusern und

deren Werkstätten bei der Planung, der Steuerung sowie der Verwaltung von verschiedenen Aufgaben in ebenjenem After-Sales-Bereich.

Eine Art der Aufgaben sind Arbeitsaufträge, bei der es sich in den meisten Fällen um die Handhabung und Abfertigung eines Autos inklusive Kundendaten handelt. Der Auftrag besteht hierbei aus einer Liste an Arbeitsabläufen, die als Jobs bezeichnet werden. Die Jobs wiederum unterteilen sich in einzelne Arbeitsschritte, die Joblines genannt werden, welche die konkreten Verrichtungen der Arbeit darstellen und somit den gesamten Arbeitsauftrag in einzelne Teilschritte vervollständigen.

Sind diese Aufträge abgeschlossen, benutzen die Mitarbeiter:innen der Autohäuser ihre Dealer-Management-Systeme, um eine Rechnung zu erstellen und diese im ERP-System zu archivieren. Das ERP bietet des Weiteren eine Schnittstelle für diese Dokumente, wie z.B die Rechnungen oder die Garantieaufträge an, die allein über Scanner die Dokumente übertragen. Dort werden die Dokumente verarbeitet und mit Hilfe eines OCR Scanners digitalisiert.

Derzeit ist allerdings die Digitalisierung nicht in der Lage, einen Kontext beziehungsweise (bzw.) eine Semantik für diese Dokumente zu erstellen. Idealerweise kann dies genutzt werden, um aus den Dokumenten Arbeitsaufträge zu generieren und somit zu digitalisieren. Demzufolge ergibt sich hier an der Stelle die Möglichkeit, einen neuen Ansatz zu testen, infogedessen die Informationen aus diesen Dokumenten als Daten erhaltbar sind.

## 2.2 Analyse

Das Extrahieren von Daten ist eine gängige Methode, um Informationen aus verschiedenen Systemen wie Datenbanken oder Software as a Service (SaaS) Plattformen zu erhalten. Durch diese Beschaffung können die Daten weiter verarbeitet werden, wodurch neue Lösungsmöglichkeiten für das eigene System bereitzustellen. Die Arten des Extrahierens unterscheiden sich hierbei im Zeitverlauf und der Herangehensweise. So können sie extrahiert werden, sobald Änderungen der Daten beobachtet oder mitgeteilt worden sind. Durch diese Herangehensweise werden so die Daten schrittweise herangeschafft [36].

Des Weiteren gibt es die Option, eine komplette Extraktion durchzuführen. Dieser Ansatz kann sich in vielen Fällen als nachteilig erweisen, da die Daten jedes mal bei Anpassungen der ursprünglichen Information neu verarbeitet werden müssen. Aufgrund des Bezugs der Problematik im Rahmen der Thesis auf Dokumente, die bereits im ERP-System archiviert wurden, trifft dieser Fall hier nicht zu.

### 2.2.1 Extraktionsbibliotheken

Für das Data Mining von PDF Dateien existieren bereits Lösungen, die von großen Unternehmen wie Amazon Web Services (AWS) oder Adobe angeboten werden. So nutzen Produkte wie Textractor [15] von AWS oder Adobes Extractor API [19] künstliche Intelligenz, Machine Learning und Optical Character Recognition (OCR), um die Extraktion der Daten zu ermöglichen. Unternehmen wie ABBYY [14] haben sich bereits auf diesem Gebiet spezialisiert und sind erfolgreich im Umgang mit der Datenextraktion. Auch existieren bereits Open-Source Bibliotheken, die sich mit dem Entnehmen der Daten aus PDF Dokumenten auseinandersetzen.

Die meisten der Open-Source Bibliotheken lassen sich hinsichtlich der Aufteilung der Aufgaben gruppieren. So erlauben unter anderem PDFMiner [41] oder Apache Tika [16], welches vor der Extraktion der Texte und Metadaten noch die Klassifizierung und Identifizierung des Medientyps von Dateien anhand einer umfangreichen Hierarchie besitzt, Texte aus PDF Dokumenten zu gewinnen [9]. Funktionalitäten für das Extrahieren von Daten aus Tabellen bieten Projekte wie Tabula [38] oder Camelot [18] an. Diese Projekte decken ferner einen weiteren Aspekt durch die Nutzung der Funktionalitäten ab.

Bei den beiden zuletzt genannten Bibliotheken weisen sich niedrige Fehlerquoten [17] und die Nutzung von einer Fuzzy Logik auf. Camelot ermöglicht überdies ein Web Interface, mit dessen Hilfe eine simple Extraktion mittels einen Browser lokal stattfinden kann. Weitere Bibliotheken, wie Textricator [28] sind umfangreicher gestaltet und ergeben für die Anfragen spezifischer Inhalte geeignete Schnittstellen.

Doch auch wenn dies mit textbasierten Dokumenten funktioniert und der Export flexibel ist, können zunächst weder nicht-textbasierte noch komplexere PDF Dokumente verarbeitet werden. Des Weiteren sind die Verarbeitungen nicht automatisierbar und die Nutzer:innengruppe wird durch eine fehlende grafische Komponente eingeschränkt. Aus dieser Problematik resultierend, zeigt sich, dass community-angetriebene Projekte wie PdfMiner.six [30], das eine Abspaltung des bereits erwähnten PdfMiner ist, und PdfPlumber [35], welches wiederum auf PdfMiner.six basiert, geeignete Alternativen darstellen.

PdfPlumber stellt im Vergleich zu seinem Ausgangsprojekt überdies eine Tabellenextraktion bereit und bietet für beide Aspekte der Extraktion eine Schnittstelle an. Es stellt eine Kommandozeile, die Möglichkeit, visuelles Debugging zu nutzen, und Funktionalitäten wie das Entfernen von Duplikaten in Texten, zur Verfügung.

Das visuelle Debugging, welches in Abbildung 2.1 zu sehen ist, ermöglicht es unter anderem, die Texte des Dokuments hervorzuheben, was wiederum die Extraktion greifbarer darlegt und die Entwicklung mit den Funktionalitäten unterstützt. Auch die Funktionalität des Entfernen von Duplikaten kann dann zum Einsatz kommen, wenn Dokumente bei ihrer Erstellung oder Verarbeitung versehentlich die selben Einträge nochmal im Quellcode des PDFs besitzen. In dieser Abbildung sind die persönlichen Daten des Auftrags anonymisiert und deshalb verpixelt.

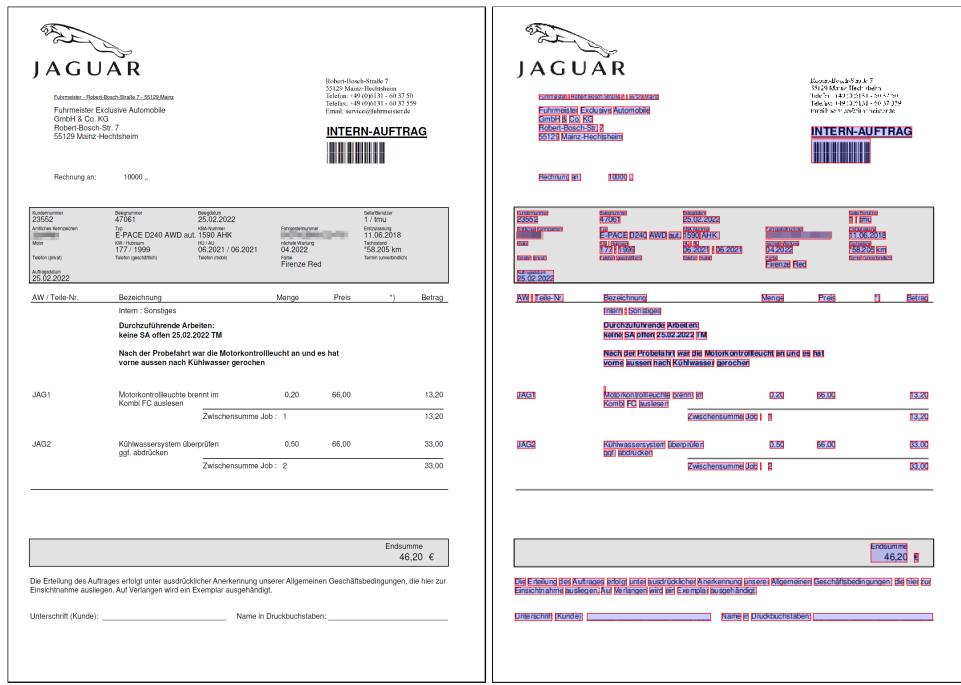


Abbildung 2.1: visuelles Debugging bei einem Dokument

Für die Auswahl einer Extraktionsbibliothek ist auch die dazugehörige Programmiersprache für das System der Datenextraktion, in der die Bibliothek umgesetzt worden ist, relevant. Darunter fallen die bereits genannten Bibliotheken, welche sich in zwei Sprachen gruppieren lassen. Projekte wie Tika, Tabula und Textricator sind mit Hilfe von Java implementiert, während die restlichen, aufgezählten Bibliotheken in Python geschrieben sind [10]. Für Tabula gilt hier hingegen die Ausnahme, dass es für das Projekt unterschiedliche Wrapper für weitere Programmiersprachen wie Python gibt. Hieraus ist zu beobachten, dass die Nutzung von Python viele mögliche Extraktionswerkzeuge erlaubt, welches sich für die spätere Umsetzung als noch bedeutsam erweist.

Die Hürden für eine komplett automatische Extraktion bestehen jedoch nach wie vor. So ist nämlich nicht ersichtlich, wie das zu erwartende Verhalten der Logik der Extraktion für den generellen Fall auszusehen hat. Eine differenzierte Extraktion für weitere Eigenschaften eines Dokuments, wie zum Beispiel Zeilenumbrüche von Absätzen, die Seitennummern, die Kopf- und Fußzeilen, die Formatierung et cetera (etc.) ist daher nötig. Die Frage, die sich dabei stellt, ist, welche Eigenschaften eines Dokuments konkret zusätzlich extrahiert werden sollen. Um eine Auswahl zu treffen, müssen die Arten der Dokumente, die in dem ERP-System auftreten, präziser durchleuchtet werden.

### 2.2.2 Dokumentarten

Bei den Dokumenten, die in das ERP-System eingescannt werden, handelt es sich in der Mehrheit um Garantie- und Werkstattaufträge und Rechnungen. Jedes Autohaus benutzt hierbei ein individuelles Muster bzw. Format für die jeweilige Art des Dokuments. Dabei ist jedoch der Aufbau dieser Dokumente zu Teilen indirekt durch die von den Autohaus genutzten Dealer-Management-Systeme vorgegeben.

Ebendaher passiert es, dass es Autohäuser gibt, welche das gleiche DMS verwenden und zudem darüber hinaus auch einen detailliert angepassten Dokumentenaufbau für ihre Aufträge benutzen. Dem Umfang dieser Thesis geschuldet werde ich mich auf drei Dokumententypen von verschiedenen Autohäusern mit ihren jeweils genutzten DMS beschränken und anhand jener drei Typen mein Vorgehen exemplarisch demonstrieren. Die Abbildungen der Dokumente in diesem Abschnitt zeigen in einigen Fällen persönliche Daten und wurden deshalb, wie in der Einleitung beschrieben, anonymisiert.

In Abbildung 2.2 wird die erste Art eines Auftrags dargestellt. Bei diesem digitalen Schriftstück handelt es sich zunächst von der Form her um eine Garantierechnung des Dealer-Management-Systems Care. Das Dokument besitzt drei Bereiche, die relevante Informationen für einen Arbeitsauftrag enthalten. In der oberen Hälfte befindet sich zunächst das Adressfeld, welches die Kundeninformationen im genormten Adressformat enthält. Unter dem Adressfeld befindet sich ein weiterer Abschnitt, in dem die Fahrzeugdaten festgehalten werden.

Hierbei ist zu beobachten, dass dieser Abschnitt sich mit einer Tabelle vergleichen lässt. Die einzelnen Einträge werden mit jeweils unterschiedlich großen Abständen verteilt dargestellt, gleichzeitig erfüllen sie eine Gesamthöhe pro Spalte beziehungsweise eine Gesamtbreite pro Höhe einer Tabelle. Gleichwohl fällt auf, dass sich — im Gegensatz zur Anzahl der Zeileneinträge — die Anzahl der Spalteneinträge pro Zeile unterscheidet.

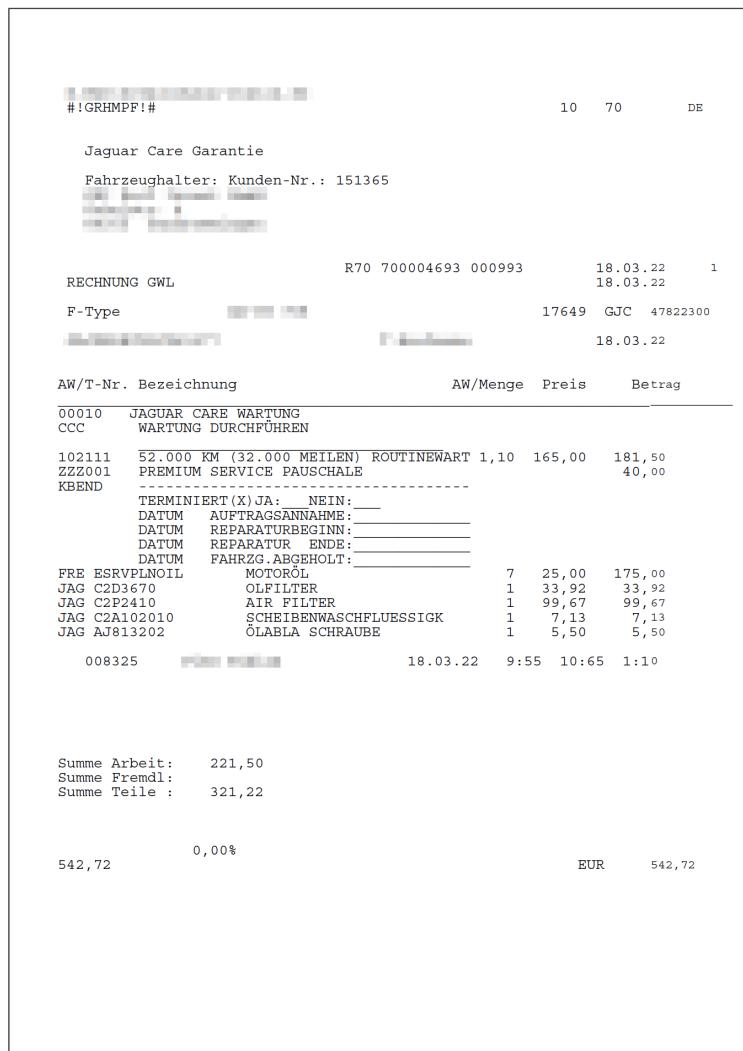


Abbildung 2.2: Exemplar eines Garantieauftrags

Zudem fehlen jegliche Einrahmungen beziehungsweise jegliche Trennlinien für Zeilen und Spalten. Bei den Einträgen in diesem Abschnitt geht es um die Abrechnungsnummer, das Datum der Reparatur, den Fahrzeugmodellnamen, das Kfz-Kennzeichen, den zuletzt abgelesenen Kilometerzählerstand, die Arbeitsauftragsnummer, der Fahrzeug-Identifikationsnummer beziehungsweise der Vehicle Identification Number (VIN), die/die zuständige/n Autohausmitarbeiter:in und das Datum der Erstellung des Arbeitsauftrags. Verpixelt und damit anonymisiert wurden die Felder des Kfz-Kennzeichens, der VIN und der/des zuständigen Mitarbeiter:in.

Im unteren Bereich wird eine Tabelle durch die Aufzählung der einzelnen Jobs und Joblines dargestellt. Die Tabelle ist an der Kopfzeile zu erkennen, die die

Jobs und Joblines in die Arbeitsnummer beziehungsweise in die Teilenummer, in die Bezeichnung, in die Menge des Arbeitszeitwertes, in den Preis und in den Betrag übersichtlich aufteilt. Die Teilenummern beziehen sich hierbei auf die Identifikationsnummer der Reparaturteile. Der Arbeitszeitwert ist dabei eine Einheit für die genaue Abrechnung der Arbeitszeiten, um eine Aufschlüsselung der Stunden zu ermöglichen. [13] Die Menge wird hierbei als Reparaturzeit oder als Anzahl der Elemente angegeben. Daneben existiert bei dieser Tabelle nur für die Kopfzeile eine untere Trennlinie. Auch hier sind Probleme bezüglich (bzgl.) der Form der Tabelle zu erkennen.

Während die ersten vier Zeilen noch dezent erscheinen, besitzt die fünfte Zeile im Abschnitt mit der Bezeichnung einen längeren Text, sodass der restliche Text in weiteren Zeilen in der gleichen Spalte darunter geschrieben steht. Die Abstände zwischen den Spalten insgesamt scheinen konsistenter zu sein, sind jedoch in der Abbildung 2.2 in mehreren Zeileneinträgen Überläufe bei den Arbeitsnummern bzw. den Teilenummern zu sehen. In der letzten Zeile ist darüber hinaus zu erkennen, dass die Einträge zu Teilen auch verschoben dargestellt werden, was eine eindeutige Erkennung der Positionierung noch weiter erschwert. Inhaltlich werden Jobs mit den dazugehörigen Joblines darunter angereiht dargestellt.

Dies ist durch die Codierung der Arbeitsnummern bzw. der Teilenummer zu erkennen, die Hierarchie ist durch das jeweilige Dealer-Management-System vorgegeben. In der ersten Spalte können daher Codes von Jobs, Reparaturzeiten, Ersatzteilen, Fremdleistungen, Stempelzeiten und Kundenbeschwerden auftreten.

Für die Codierung ist keine standardisierte Spezifikation vorhanden, weshalb das für jedes Autohaus und seine Nutzung der DMS individuell definiert ist. So sind die Codes der Jobs als eine fünfstellige Zeichenkette aus Ziffern bestimmt, die mit den Ziffern 00 angefangen. Die Reparaturzeiten dagegen besitzen eine sechsstellige Zeichenkette aus Ziffern. Unterhalb der Tabelle werden am Ende des Dokuments schließlich die gesamten Kosten aus den Betragseinträgen summiert dargestellt. Diese Summe lässt sich wiederum in Kosten der Arbeit und der Teile aufteilen.

In Abbildung 2.3 wird eine Rechnung der Formel 1 DMS dargestellt. Auch hier sind sämtliche personenbezogenen Daten verpixelt und anonymisiert worden. Im Vergleich zur vorherigen Abbildung 2.2 ist ein ähnlicher Aufbau zu sehen. Während das Adressfeld geläufig aussieht, sind jedoch die Fahrzeug- und Kundendaten diesmal in zwei unterschiedlichen Tabellen aufgeteilt.

Die erste Tabelle befindet sich im oberen Teil der rechten Seite des Dokuments, wo die einzelnen Kundeninformationen aufgelistet sind. Die Tabelle für die

ahg Autohandelsgesellschaft		BMW Service																																																								
BMW Vertragshändler																																																										
ahg Autohandelsgesellschaft mbH - Senefelderstr. 2 - D-73760 Ostfildern																																																										
		Kunden-Nr. : 444515-33 Rechnungs-Nr. : 133 - Rechnungsdatum : Annemer : Auftrag/LS-Nr. : 115025 Auftragsdatum : 24.02.2022 Hauptauftrag-Nr: 112985 Seite : 1  Leistungsdatum : 24.02.2022																																																								
<b>TESTRECHNUNG</b>																																																										
Filiale : E Ostfildern																																																										
<table border="1"> <thead> <tr> <th>Fahrz.Nr.</th> <th>Modell/Typ</th> <th>Fahrg.-Nr./EZ/HU</th> <th>km Ein/Aus</th> <th>angem./ausgef.</th> </tr> </thead> <tbody> <tr> <td>[REDACTED]</td> <td>VU31 320d Touring</td> <td>[REDACTED] 20.09.2006 / 09/23</td> <td>177393 177584</td> <td>02321 02019</td> </tr> </tbody> </table>				Fahrz.Nr.	Modell/Typ	Fahrg.-Nr./EZ/HU	km Ein/Aus	angem./ausgef.	[REDACTED]	VU31 320d Touring	[REDACTED] 20.09.2006 / 09/23	177393 177584	02321 02019																																													
Fahrz.Nr.	Modell/Typ	Fahrg.-Nr./EZ/HU	km Ein/Aus	angem./ausgef.																																																						
[REDACTED]	VU31 320d Touring	[REDACTED] 20.09.2006 / 09/23	177393 177584	02321 02019																																																						
<table border="1"> <thead> <tr> <th>Nummer</th> <th>Bezeichnung</th> <th>Menge/AW/St</th> <th>E-Preis</th> <th>Gesamt</th> </tr> </thead> <tbody> <tr> <td>0000556</td> <td>Fahrzeugtest durchführen</td> <td>2</td> <td>10,66</td> <td>21,32</td> </tr> <tr> <td>1223505</td> <td>Alle Glühlampen ersetzen</td> <td>16</td> <td>13,63</td> <td>218,08</td> </tr> <tr> <td>6100006</td> <td>Prüfplan für Vorglühlanlage abgearbeitet</td> <td>1</td> <td>13,63</td> <td>13,63</td> </tr> <tr> <td>6121528</td> <td>nicht i.O</td> <td></td> <td></td> <td></td> </tr> <tr> <td></td> <td>Bordnetzspannung unterstützen</td> <td>1</td> <td>13,63</td> <td>13,63</td> </tr> <tr> <td></td> <td>Bordnetzbatterie nachladen</td> <td></td> <td></td> <td></td> </tr> <tr> <td>11612246945</td> <td>Profilabdichtung</td> <td>4</td> <td>4,27</td> <td>17,08</td> </tr> <tr> <td>11617790198</td> <td>Profilabdichtung</td> <td>4</td> <td>4,27</td> <td>17,08</td> </tr> <tr> <td>12237786869</td> <td>Glühlampe</td> <td>4</td> <td>14,94</td> <td>59,76</td> </tr> <tr> <td></td> <td><b>Zwischensumme</b></td> <td></td> <td></td> <td><b>360,58</b></td> </tr> </tbody> </table>				Nummer	Bezeichnung	Menge/AW/St	E-Preis	Gesamt	0000556	Fahrzeugtest durchführen	2	10,66	21,32	1223505	Alle Glühlampen ersetzen	16	13,63	218,08	6100006	Prüfplan für Vorglühlanlage abgearbeitet	1	13,63	13,63	6121528	nicht i.O					Bordnetzspannung unterstützen	1	13,63	13,63		Bordnetzbatterie nachladen				11612246945	Profilabdichtung	4	4,27	17,08	11617790198	Profilabdichtung	4	4,27	17,08	12237786869	Glühlampe	4	14,94	59,76		<b>Zwischensumme</b>			<b>360,58</b>
Nummer	Bezeichnung	Menge/AW/St	E-Preis	Gesamt																																																						
0000556	Fahrzeugtest durchführen	2	10,66	21,32																																																						
1223505	Alle Glühlampen ersetzen	16	13,63	218,08																																																						
6100006	Prüfplan für Vorglühlanlage abgearbeitet	1	13,63	13,63																																																						
6121528	nicht i.O																																																									
	Bordnetzspannung unterstützen	1	13,63	13,63																																																						
	Bordnetzbatterie nachladen																																																									
11612246945	Profilabdichtung	4	4,27	17,08																																																						
11617790198	Profilabdichtung	4	4,27	17,08																																																						
12237786869	Glühlampe	4	14,94	59,76																																																						
	<b>Zwischensumme</b>			<b>360,58</b>																																																						
<table border="1"> <tr> <td>0,00% MwSt von</td> <td>360,58 =</td> <td>0,00</td> <td></td> </tr> <tr> <td></td> <td></td> <td></td> <td style="text-align: right;">Gesamt Lohn EUR 266,66 Gesamt Teile EUR 93,92</td> </tr> <tr> <td></td> <td></td> <td></td> <td style="text-align: right;"><b>Endsumme EUR 360,58</b></td> </tr> </table>				0,00% MwSt von	360,58 =	0,00					Gesamt Lohn EUR 266,66 Gesamt Teile EUR 93,92				<b>Endsumme EUR 360,58</b>																																											
0,00% MwSt von	360,58 =	0,00																																																								
			Gesamt Lohn EUR 266,66 Gesamt Teile EUR 93,92																																																							
			<b>Endsumme EUR 360,58</b>																																																							
Zahlbar sofort!																																																										
<b>Hausanschrift</b> ahg Entenmann - Eine Niederlassung der ahg Autohandelsgesellschaft mbH Senefelderstraße 2 73760 Ostfildern		<b>Kontakt</b> Telefon: +49 (0) 711/44983-0 Fax: +49 (0) 711/44983-83 E-Mail: ostfildern@ahg-entenmann.de <a href="http://www.ahg-entenmann.de">www.ahg-entenmann.de</a>	<b>Bankverbindung</b> Kreissparkasse Freudenstadt IBAN DE06 6425 1060 0000 5435 43 BIC SOLADES1FDS	<b>Geschäftsführer</b> Alexander Kramer Thomas Lindrich	<b>Registergericht</b> Stuttgart HRB 44 304 Sitz Horb a. N. USt-ID-Nr. DE811162775																																																					

Abbildung 2.3: Exemplar einer Rechnung

Fahrzeuginformationen befindet sich im unteren Bereich der oberen Hälfte des Dokuments und ist aufgrund der vorhandenen Trennlinien eine klassische Tabelle. Im letzten Teil der Formel 1 Rechnung befindet sich die Liste der Job und Joblines.

Hier fallen ähnliche Problematiken, wie die unterschiedlichen Abstände zwischen den Spalten der Einträge im Vergleich zu dem Care Garantieauftrag auf. Auch existieren Überläufe der Einträge, allerdings treten diese nur in den Feldern der Bezeichnung auf. Die Gesamtkosten werden dann am Ende des Dokuments in den Teilsummen der Beträge bekannt gegeben.

Bei der dritten und damit letzten Dokumentart (Abbildung 2.4) handelt es sich

 <b>JAGUAR</b>																																																																	
<small>Fahrmeister - Robert-Bosch-Straße 7 - 55129 Mainz</small> <b>Fahrmeister Exclusive Automobile</b> <b>GmbH &amp; Co. KG</b> <b>Robert-Bosch-Str. 7</b> <b>55129 Mainz-Hechtsheim</b>			<small>Robert-Bosch-Straße 7 55129 Mainz-Hechtsheim Telefon: +49 (0)6131 - 60 37 50 Telefax: +49 (0)6131 - 60 37 559 Email: service@fahrmeister.de</small>																																																														
<b>INTERN-AUFRAG</b>																																																																	
																																																																	
<small>Rechnung an: 10000 ..</small>																																																																	
<table border="1" style="width: 100%; border-collapse: collapse;"> <tr> <td>Kundennummer 23552</td> <td>Begrenzungsnummer 47061</td> <td>Begrenzungsdatum 25.02.2022</td> <td>Hilfs-Nr. Hilfs-Nr.</td> <td>Seller/Berater 1 / Immo</td> </tr> <tr> <td>Amtliches Kennzeichen [REDACTED]</td> <td>Type E-PACE D240 AWD aut.</td> <td>Motor 1590 AHK</td> <td>Fahrgerätenummer [REDACTED]</td> <td>Erstzulassung 11.06.2018</td> </tr> <tr> <td>Motor [REDACTED]</td> <td>KW / Hubraum 177 / 1999</td> <td>HU / AU</td> <td>nächste Wartung 04.2022</td> <td>Tachotstand *58.205 km</td> </tr> <tr> <td>Telefon (privat)</td> <td>Telefon (geschäftlich)</td> <td>Telefon (mobil)</td> <td>Farbe Rot</td> <td>Termin (unverbindlich) Firenze Red</td> </tr> <tr> <td colspan="6">Auftragsdatum 25.02.2022</td> </tr> </table>						Kundennummer 23552	Begrenzungsnummer 47061	Begrenzungsdatum 25.02.2022	Hilfs-Nr. Hilfs-Nr.	Seller/Berater 1 / Immo	Amtliches Kennzeichen [REDACTED]	Type E-PACE D240 AWD aut.	Motor 1590 AHK	Fahrgerätenummer [REDACTED]	Erstzulassung 11.06.2018	Motor [REDACTED]	KW / Hubraum 177 / 1999	HU / AU	nächste Wartung 04.2022	Tachotstand *58.205 km	Telefon (privat)	Telefon (geschäftlich)	Telefon (mobil)	Farbe Rot	Termin (unverbindlich) Firenze Red	Auftragsdatum 25.02.2022																																							
Kundennummer 23552	Begrenzungsnummer 47061	Begrenzungsdatum 25.02.2022	Hilfs-Nr. Hilfs-Nr.	Seller/Berater 1 / Immo																																																													
Amtliches Kennzeichen [REDACTED]	Type E-PACE D240 AWD aut.	Motor 1590 AHK	Fahrgerätenummer [REDACTED]	Erstzulassung 11.06.2018																																																													
Motor [REDACTED]	KW / Hubraum 177 / 1999	HU / AU	nächste Wartung 04.2022	Tachotstand *58.205 km																																																													
Telefon (privat)	Telefon (geschäftlich)	Telefon (mobil)	Farbe Rot	Termin (unverbindlich) Firenze Red																																																													
Auftragsdatum 25.02.2022																																																																	
<table border="1" style="width: 100%; border-collapse: collapse;"> <thead> <tr> <th>AW / Teile-Nr.</th> <th>Bezeichnung</th> <th>Menge</th> <th>Preis</th> <th>*)</th> <th>Betrag</th> </tr> </thead> <tbody> <tr> <td colspan="6">Intern : Sonstiges</td> </tr> <tr> <td colspan="6">Durchzuführende Arbeiten: keine SA offen 25.02.2022 TM</td> </tr> <tr> <td colspan="6">Nach der Probefahrt war die Motorkontrollleucht an und es hat vorne aussen nach Kühlwasser gerochen</td> </tr> <tr> <td>JAG1</td> <td>Motorkontrollleuchte brennt im Kombi FC auslesen</td> <td>0,20</td> <td>66,00</td> <td></td> <td>13,20</td> </tr> <tr> <td></td> <td></td> <td>Zwischensumme Job : 1</td> <td></td> <td></td> <td>13,20</td> </tr> <tr> <td>JAG2</td> <td>Kühlwassersystem überprüfen ggf. abdrücken</td> <td>0,50</td> <td>66,00</td> <td></td> <td>33,00</td> </tr> <tr> <td></td> <td></td> <td>Zwischensumme Job : 2</td> <td></td> <td></td> <td>33,00</td> </tr> <tr> <td colspan="6"></td> </tr> <tr> <td colspan="6" style="text-align: right;">Endsumme 46,20 €</td> </tr> </tbody> </table>						AW / Teile-Nr.	Bezeichnung	Menge	Preis	*)	Betrag	Intern : Sonstiges						Durchzuführende Arbeiten: keine SA offen 25.02.2022 TM						Nach der Probefahrt war die Motorkontrollleucht an und es hat vorne aussen nach Kühlwasser gerochen						JAG1	Motorkontrollleuchte brennt im Kombi FC auslesen	0,20	66,00		13,20			Zwischensumme Job : 1			13,20	JAG2	Kühlwassersystem überprüfen ggf. abdrücken	0,50	66,00		33,00			Zwischensumme Job : 2			33,00							Endsumme 46,20 €					
AW / Teile-Nr.	Bezeichnung	Menge	Preis	*)	Betrag																																																												
Intern : Sonstiges																																																																	
Durchzuführende Arbeiten: keine SA offen 25.02.2022 TM																																																																	
Nach der Probefahrt war die Motorkontrollleucht an und es hat vorne aussen nach Kühlwasser gerochen																																																																	
JAG1	Motorkontrollleuchte brennt im Kombi FC auslesen	0,20	66,00		13,20																																																												
		Zwischensumme Job : 1			13,20																																																												
JAG2	Kühlwassersystem überprüfen ggf. abdrücken	0,50	66,00		33,00																																																												
		Zwischensumme Job : 2			33,00																																																												
Endsumme 46,20 €																																																																	
<small>Die Erteilung des Auftrages erfolgt unter ausdrücklicher Anerkennung unserer Allgemeinen Geschäftsbedingungen, die hier zur Einsichtnahme ausliegen. Auf Verlangen wird ein Exemplar ausgehändigt.</small>																																																																	
<small>Unterschrift (Kunde): _____ Name in Druckbuchstaben: _____</small>																																																																	

Abbildung 2.4: Exemplar eines Werkstattauftrags

um einen Werkstattauftrag von dem Dealer-Management-System KFZ3000. Auch dieses hier abgebildete Dokument wurde aus Datenschutzgründen anonymisiert. Dieser hier gezeigte Auftrag lässt sich in Bezug auf die Aufteilung der einzelnen Segmente mit dem Care-Warranty-Dokument vergleichen. Während auch das Adressfeld erneut normiert abgebildet ist, werden Kunden- und Fahrzeugdaten über Schlüssel-Wert Anordnungen in einem größeren Feld dargestellt.

Die untere Hälfte des Werkstattauftrags besitzt gleicherweise wie die bereits anderen genannten Dokumente eine tabellenähnliche Auflistung der Job und Joblines. Ebenfalls sind hier Überläufe und unterschiedliche Abstände in dem Bereich zu erkennen. Hinzu kommt, dass, im Gegensatz zu den anderen Dokumentarten, zwischen den Zeilen ein Art Summenstrich hinzugefügt wird,

der die Anzahl der Jobs anzeigen soll. Außerdem wird im unteren Bereich des Dokuments lediglich die gesamte Betragssumme gezeigt.

Insgesamt lässt sich feststellen, dass alle hier vorgestellten Dokumentarten und ihre Hürden durch eine gemeinsame Problematik miteinander verbunden ist. Die Darstellung der Kunden- und Fahrzeuginformationen wird entweder in einer Tabellenform gemeinsam (siehe Abbildung 2.2) oder in zwei verschiedenen Tabellen (siehe Abbildung 2.3) abgebildet. Diese Tabellenform besitzt außerdem selten Trennlinien, welche geeignet sind, um eine derartige Tabelle als solche definieren zu können. Für die Liste der Job und Joblines tritt das gleiche Problem auf.

Die Auflistung der Job und Joblines als Tabelle wird allein durch ihre Anordnung der Einträge und deren Abstände dazwischen als solche erkenntlich, jedoch bricht sie in den prototypischen Dokumenten aber mindestens (mind.) einmal die Form durch Überläufe oder Verschiebungen der Texte. Ein weiterer relevanter Aspekt, welcher übersehen werden kann, ist, dass die Aufträge mehr als eine Seite haben können.

Dies tritt für Dokumente auf, welche eine längere Auflistung der Job und Joblines besitzen und somit auf weiteren Seiten dargestellt werden muss. Für die Extraktion der Liste muss daher auch überprüft werden, ob sich diese über weitere Seiten erstreckt um sie zusammenzuführen und zu verarbeiten. Es ist festzustellen, dass verschiedene Tabellenstrukturen für unterschiedlichen Dokumentarten existieren. Dieses Angelegenheit besteht, da bisher für Tabellen keine universelle Standardisierung definiert ist.

Damit diese Formen durch eine Logik des Extrahierens abgedeckt werden, besteht die Möglichkeit der Fallunterscheidung. Bei dieser Unterscheidung sollen die Dokumente anhand ihrer Arten konzipiert und definiert werden, sodass die Entnahme detaillierter stattfinden kann. Für andere Bereiche eines Dokuments wie dem Adressfeld werden gewöhnliche Funktionalitäten der Extraktion genutzt und zur Verfügung gestellt. Diese können dann von allen weiteren Dokumentarten geteilt und genutzt werden, sodass eine Verallgemeinerung verschiedener Dokumententypen ermöglicht wird.

### 2.2.3 Frameworks

Damit das System für den Prozess der Extraktion als solches sich zeitnah im Rahmen einer Thesis umsetzen lässt, können Frameworks dem ganzen Zeitfenster entgegenkommen. Im Zuge dessen werden für die Teilsysteme verschiedene Technologien betrachtet und in Erwägung gezogen. So wird zunächst die symbo-

lische künstliche Intelligenz dem ersten Teilsystem zugeordnet und in seiner Art unterschieden. Zudem müssen die Realisierungsmöglichkeiten der symbolischen KI betrachtet und aus den verschiedenen Arten eines wissensbasierten Systems muss ein Modell ausgewählt werden.

Ein solches wissensbasiertes System ist hierbei der Oberbegriff für Programme, die mit Hilfe einer Wissensbasis Mechanismen der Schlussfolgerung nutzen, um Lösungen für Probleme im dafür gewählten Anwendungsbereich zu finden [3]. Es existieren verschiedene Modelle eines wissensbasierten Systems, die abhängig vom Anwendungsfall passend sind. Folgendermaßen gibt es den Ansatz des regelbasierten Systems bzw. des Produktionssystems, bei dem die Schlussfolgerung über Regeln und Fakten, die von Benutzer:innen definiert werden, konstruiert wird.

Bekannt für die Erstellung eines solchen Systems ist das in der Programmiersprache C geschriebene Werkzeug *CLIPS*[2]. Dieses Werkzeug verfügt über eine eigene Syntax, welche von der Syntax des von der Inference Corporation entwickelten Expertensystems *ART* für die Regeln und Fakten abgeleitet wurde und damit zahlreiche Gemeinsamkeiten beziehungsweise Ähnlichkeiten aufweisen. [26]. Die Umsetzung wird ebenso mit dem Wrapper *clipsy* für die Programmiersprache Python zur Nutzung bereitgestellt.

Eine Alternative zu *CLIPS*, die zeitlich danach entwickelt wurde, ist das Expertensystem *NEXPERT OBJECT*, das sich bis auf die Datenbankintegration nur marginal in der Nutzung der Regel- und Faktendefinitionen unterscheidet [1] und obendrein keine aktive Entwicklung und Wartung existiert. Andere moderne Umsetzungen konzentrieren sich im Vergleich eher auf die als Regelinterpreter verstandene Inferenzmaschine. Projekte wie *Pyke* [24], *Durable Rules* [34] oder *ExpertA* [31], dem Nachfolger von einem Expertensystem Framework namens *pyKnow*, erlauben es, eine Regelmenge zu definieren und die einzelnen Regeln mit selbstdefinierten Funktionen zu koppeln.

Für die Entwicklungsumgebung, die den Zugang zum System darstellen soll, eignen sich sowohl Nutzungsschnittstellen bzw. User Interface (UI) Bibliotheken für den Desktop als auch für den Webbereich. Die Priorität liegt hierbei bei der Erstellung der einzelnen Komponenten der graphischen Benutzungsoberfläche bzw. der Graphical User Interface (GUI). Folglich können Projekte wie *Qt* [33] und das in C++ geschriebene *ImGui* [29] Bibliotheken bereitstellen, die auf einer nativen Ebene funktionieren und demgemäß in verschiedenen Anwendungsfällen genutzt werden. Die letztere genannte Bibliothek benutzt intern einen Zustandsautomaten, um die Render-Pipeline darzustellen (diese erfordert mehr Erfahrung mit der Grafikprogrammierung), dass jenes verwendet werden

kann [5].

Dem gegenüber stehen abstraktere im Front-End Bereich verwendete UI-Lösungen wie das Benutzen eines Web Frameworks. Bekannte Bibliotheken wie *Vue* und *React* ermöglichen eine schnelle und gängige Umsetzung einer Oberfläche, die auch die Zwecke einer Entwicklungsumgebung erfüllen können. Weitere Kandidaten wie *Svelte* [37] versuchen durch das Nutzen eines Compiler, die Arbeit von dem Browser auf die Build Zeit umzulagern.

Für das Teilsystem, welches den Ansatz des maschinellen Lernens nutzen soll, sind gleicherweise hier ML-Frameworks eine geeignete Lösung. Kandidaten sind die zurzeit konventionellen Frameworks wie *TensorFlow* [39], *pyTorch* [32] und *spaCy* [22]. Jene bieten für die Anwendungsgebiete unter anderem in der Bilderkennung, der Computer Vision und des Neuro-Linguistische Programmieren (NLP) eine automatisierte Lösung an. Weitere neue Projekte wie *Fonduer* [11] fokussieren sich mit Hilfe von schwachem überwachten Lernen (supervised learning) auf die Extraktion von umfangreichen formatierten Daten, worunter auch PDF Dokumente fallen. Dieser Lernansatz findet auch bei nicht vollständig beschrifteten Trainingsdaten einen Anwendungszweck [12], weswegen sich das für einfache Dokumente als praktisch erweisen kann.

## **Kapitel 3**

# **Konzeption und Umsetzung**

Für den Sprung zur Umsetzung bedarf es als nächstes die Konzeption des technischen Rahmens. Zunächst wird der Aufbau des Projekts vorgestellt, wie die beschriebene Problematik gelöst werden soll. Danach wird der Verlauf der Entwicklung über die Aufteilung des Systems in seine Komponenten dargestellt. Jene beschreiben im Detail ihre Eigenschaften und Zusammenhänge.

### **3.1 Aufbau**

Für die Struktur des Systems ist vorerst die Untergliederung des Projekts relevant. Sie kann je nach einem ausgewählten Architekturmuster unterschiedlich gestaltet werden. Da die Teilsysteme wiederum als eigene Systeme dargestellt werden können und für die einzelnen Anwendungsfälle kommunizieren beziehungsweise interagieren müssen, ist hier der Ansatz der verteilten Systeme geeignet. Die Kategorie der verteilten Systeme ist in weitere unterschiedliche Architekturmuster gegliedert. Eines dieser Muster ist die Client-Server Architektur, die es erlaubt, über ein Netzwerk die Kommunikation bereitzustellen und die Teilsysteme und ihre Aufgaben zu fraktionieren.

Dahin gehend gibt es drei Komponenten mit unterschiedlichen Aufgaben, die in den eben beschriebenden Teilsystemen abgebildet werden: Die erste Komponente befasst sich mit der Extraktion über ein regelbasierte Logik, mit jener die Daten von mehreren Dokumenten eines Dokumententyps automatisiert erhalten werden. Die Zweite setzt die Entwicklungsumgebung um und ermöglicht dadurch auch jegliche Erstellung und Bearbeitung von Regeln über Textdateien. Die dritte und letzte Komponente setzt für die Extraktion der Dokumente den Lösungsansatz des Machine Learnings um.

Innerhalb des Architekturmusters fungieren die erste und dritte Komponente als Server, die die Logik der Extraktion ausführen sollen. Die Entwicklungsumgebung als zweite Komponente ist im Gegensatz dazu als Client zu betrachten, der den Benutzer:innen Änderungen in Bezug auf Regeldefinitionen erlaubt. Damit dieser Netzwerkansatz für die Architektur umgesetzt werden kann, müssen die Komponenten Schnittstellen auf der Netzwerkebene bereitstellen.

Für die jeweiligen Komponenten, die sich mit der Extraktionslogik beschäftigen, dient hier der Lösungsansatz der Benutzung eines Webservers, welcher die Anfragen verarbeitet und die verschiedenen Zustände als Antwort den Anfragen zurückgibt. Bei der Komponente der Entwicklungsumgebung eignet sich der Ansatz einer Webanwendung, mit welcher weitere Technologien aus dem Webbereich genutzt werden können. Somit wird jegliche Bearbeitung der Definitionen durch die IDE als Anfrage verschickt und die daraus folgenden Antworten als Ergebnisse präsentiert.

Für die praktische Umsetzung oder für die Entwicklung wird der Lösungsentwurf als ein Softwareprojekt in Form eines Monoliths konstruiert, welches das System als ganzes darstellt. Das Projekt trägt den Namen *Smart Document Extractor* und wird mit dem gängigen Versionsverwaltungssystem Git aufgesetzt. Die darin gegliederten Komponenten werden *Rule System*, *IDE* und *ML* genannt.

Demgemäß wird das Projekt als lokales Repository und als Remote Repository auf dem GitLab Server des Unternehmens festgehalten. Im Wurzelverzeichnis wird zudem mit der Container Virtualisierung von Docker eine betriebssystem-agnostische Umgebung für die Teilsysteme definiert. Dies ist nicht nur der Softwareentwicklung, sondern auch der Continuous Integration und deren Testschritte dienlich und ermöglicht einen Ausbau der Skalierung der Teilsysteme.

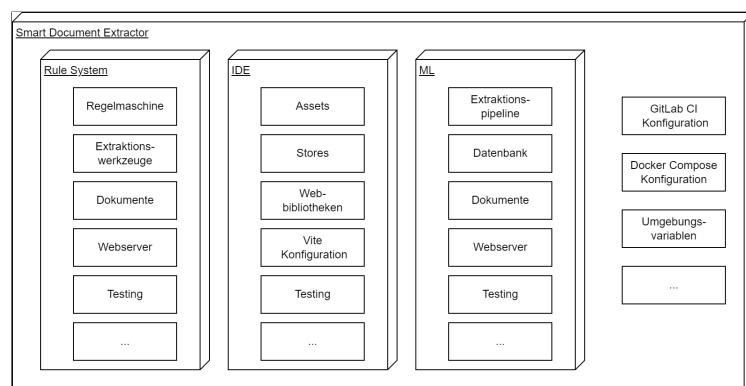


Abbildung 3.1: Struktur des Softwareprojekts

Die einzelnen Teilsysteme werden mit Hilfe einer Docker Compose Datei anschließend orchestriert, sodass die Container gemeinsam gestartet werden und ihre Kommunikation über ein gemeinsames Netzwerk geführt werden kann. Die zusätzliche Konfiguration von Umgebungsvariablen in dem Projekt erlaubt es außerdem, sensible Daten, wie die Anmeldeinformationen der Zugänge der Teilsysteme oder weitere Dienste für den Arbeitsbereich dynamisch anzupassen. Die Konfiguration wird hierbei von dem Versionsverwaltungssystem ignoriert.

Abbildung 3.1 zeigt eine Übersicht des Projekts und seine Eigenschaften, auf die im weiteren Verlauf dieser Arbeit detaillierter eingegangen wird. Dort sind neben den beschriebenen Konfigurationsdateien die Teilsysteme und deren Module als Komponenten abgebildet.

## 3.2 Symbolische KI

Für das Teilsystem der symbolischen künstlichen Intelligenz habe ich den Ansatz bzw. die Nutzung eines Wissensbasierten Systems ausgewählt. Dieser Ansatz ermöglicht die Steuerung der Extraktion über definierte Fakten und Regeln. Wie in Kapitel 2.2.3 beschrieben, gibt es viele Frameworks, die ein solches System bereitstellen können. Doch zeigt sich auch bei jenen, dass die Nutzung eines dieser Frameworks nicht für den Fall geeignet ist, da mehr Funktionalitäten als benötigt abgedeckt werden.

Ein regelbasiertes System zeichnet sich durch eine Anzahl von Regeln (sogenannte Produktionsregeln), Fakten, welche sich während des Inferenzvorgangs verändern, und durch den Regelinterpreter aus. Der Interpreter kann mit Hilfe dieser Menge die Schlussfolgerungen in Form einer Vorwärtsverkettung oder Rückwärtsverkettung durchführen [8].

Für den Kontext der Dokumentenextraktion bedarf es allein die Ausführung von Extraktionen und die Generierung neuer Fakten, sobald die benutzerdefinierten Regeln mit den bereits vorhandenen Fakten erfüllt wurden, als Funktionalitäten.

Die in dieser Arbeit vorgestellten Bibliotheken gehen mit einem größeren Aufwand der Implementierung einher, da jene Bibliotheken weitere Softwareabhängigkeiten zur Folge haben. Daher wird hier der Lösungsweg über ein eigens implementiertes Regelsystem gewählt. Der Regelinterpreter wird speziell für den Zweck der Datenextraktion entwickelt und passt sich damit an die Nutzung des gesamten Projekts an. Für die Implementierung dieses Teilsystems wird sich zudem für die Benutzung der Programmiersprache Python entschieden.

### 3.2.1 Extraktionsvorgang

Bevor auf die Regelmaschine genauer eingegangen werden kann, muss zunächst die konkrete Extraktion beleuchtet werden. Im Abschnitt 2.2.2 wurde gezeigt, dass die Hauptproblematik der Dokumente in der Extraktion der Tabellen liegt. Diesbezüglich definieren wir Tabellen, die für jede Zeile und Spalte Trennlinien besitzen, als konventionelle Tabellen. Ein Beispiel hierfür ist die Tabelle, die in Abbildung 2.3 die Fahrzeugdaten beinhaltet. Tabellen, die keine oder nur zu Teilen Trennlinien für die Zeilen und Spalten nutzen, werden als unkonventionelle Tabellen definiert. Diese Art der Tabelle tritt in den drei vorgestellten Dokumentarten in Form der Auflistung von den Jobs und Joblines auf. Andere Tabellen, die eine beliebige Form und somit die restlichen Tabellenarten darstellen, werden als benutzerdefinierte Tabelle bestimmt.

Textfelder können im Vergleich zu den Tabellen leichter extrahiert werden, weswegen die Funktionalität für alle Dokumentarten beziehungsweise Dokumententypen benutzt werden kann. Für eine Verallgemeinerung der Extraktionsfunktionalitäten wird daher eine gemeinsame Klasse namens *DocumentExtractionType* definiert. Diese gemeinsame Klasse fasst als Obermenge die Methoden, die für alle Dokumentarten als Unterklasse genutzt werden können, zusammen. Sie bietet die Möglichkeit an durch weitere Klassendefinitionen, die den Mechanismus der Vererbung nutzen, Abbildungen von unterschiedlichen Dokumententypen zu kreieren. So werden daraus folgend die Dokumentarten, die im Kapitel 2.2.2 vorgestellt wurden, durch die Klassen *CareWarranty*, *Formel1Invoice* und *KFZ300Invoice* chronologisch dargestellt.

Die gemeinsamen Funktionalitäten, die in der Oberklasse definiert sind, bestehen aus der Textextraktion von Textfeldern, der Tabellenextraktion von konventionellen Tabellen, der Textextraktion von unkonventionellen Tabellen und der Textextraktion von benutzerdefinierten Tabellen. Damit diese Funktionalitäten ausgeführt werden können, müssen Eigenschaften der Extraktionsbereiche als Parameter angegeben werden. Für alle beschriebenen Ziele existiert mindestens die Positionierung als Eigenschaft. Sie kann als Bounding Box (bbox) mit den X und Y Koordinaten für die jeweiligen Extraktionsziele aufgeführt werden.

Eine weitere Eigenschaft, die sich aus der Positionierung schließen lässt, ist die Dokumentenseite. Bei den selektierten Dokumenten treten jeweils mehrere Seiten auf, wenn die Liste der Jobs und Joblines so viele Einträge besitzt, dass diese nicht auf eine Seite passen. Aus diesem Grund ist die Seitennummer, die den Funktionen neben den Bounding Boxen mitgegeben werden, relevant für die Beschreibung des Zielbereiches. Diese Seitennummern können den Funktionen neben den Bounding Boxen mitgegeben werden. Daraus folgend werden diese

zwei Eigenschaften — die der Positionierung und die der Seitennummer — als notwendige Bedingung für jegliche Extraktionsbereiche behandelt und damit für die Logik der Methoden durch die Parametereingabe als gegeben gesehen.

Für die Umsetzung der einzelnen Funktionen wird die vorgestellte Bibliothek PdfPlumber benutzt, um für die jeweiligen Extraktionsziele mit verschiedenen Methoden die Daten zu erhalten. Die Methoden nutzen dann die Angaben der Seitennummer und der Bounding Box, sodass der Bereich der Extraktion zunächst eingeschränkt werden kann. Mit dem ausgewählten Bereich werden dann die Funktionalitäten für die Text- oder Tabellenextraktion aufgerufen.

Bei den prototypischen Dokumenten fällt vorerst die hinderliche Tabellenextraktion von unkonventionellen Tabellen und indirekt von benutzerdefinierten Tabellen auf: Die Bibliotheken können diese Tabellen mit den dafür konzipierten Funktionen nicht erkennen bzw. von diesen keine strukturellen Daten, die die Tabellen abbilden sollen, erhalten. Um dies zu umgehen, werden als Lösungswege die unkonventionellen und die benutzerdefinierten Tabellen zunächst als reine Texte extrahiert und danach werden die Einträge der jeweiligen Felder mit Hilfe von regulären Ausdrücken gefiltert.

Auch wenn der Bereich durch die Bounding Box umrahmt ist, kann der Bereich nicht relevante Texte besitzen, die die Verarbeitung erschweren. Demzufolge werden weitere Eigenschaften wie die Angabe eines Start- und Endankers benötigt, um lediglich die Zeilen aus dem Rohtext zu erhalten. Da bei den elektronisch verarbeiteten Dokumenten die Tabellen als Texte mit Zeilenumbrüchen verfasst sind, können die Zeilenumbrüche genutzt werden, sodass aus den Zeilen eine Liste generiert wird. Die Liste wiederum wird mit regulären Ausdrücken weiter verarbeitet. In Folge dieser Verarbeitung erhalten die Daten durch Zuweisungen eine strukturierte Form und stellen folglich die Semantik der Tabellen dar.

Da auch Dokumente mit mehreren Seiten existieren, bedarf es neben den Start- und Endanker eine Menge von Zwischenankern, die als Brücke für die längeren Listen dienen. Für die unkonventionellen und benutzerdefinierten Tabellen werden daher neben der Positionierung und der Seitennummern die Start- und Endanker als die Voraussetzung für jene Extraktionsfunktionalitäten benutzt. Optional bleiben die Angabe der Zwischenanker.

Die Klassen der einzelnen Dokumentarten sind für weitere Funktionalitäten, die spezifischere Zwecke für den jeweiligen Dokumenttyp erfüllen und eine weitere Semantik für die extrahierten Texte und Tabellen bilden. Diese Methoden erhalten mit Hilfe von regulären Ausdrücken die einzelnen Werte für die gewünschten Felder und weisen jene mit ähnlichen Algorithmen den Feldern zu. So werden die Daten je nach Dokumentenart detaillierter erfasst und als

komplexe Objekte verarbeitet.

### 3.2.2 Webserver

In Kapitel 3.1 wurde die Struktur des gesamten Systems definiert und die Client-Server Architektur festgelegt. Damit die Komponente der symbolischen künstlichen Intelligenz die Kommunikation über Netzwerke erlaubt, bedarf es die Implementierung eines Webservers. Insgesamt gibt es viele Ansätze, wie ein solcher Webserver aufgesetzt werden kann. Da aber die benötigten Funktionalitäten für die prototypische Entwicklung sich auf die Verarbeitung von gewöhnlichen Hypertext Transfer Protocol (HTTP) Anfragen und Antworten beschränken, reicht die Nutzung eines Web Server Gateway Interface (WSGI) Servers aus.

Für diesen Zweck eignet sich das Mikro-Framework Flask, welches eine zeitnahe Umsetzung und Integration in das System ermöglicht [6]. Über die Umgebungsvariablen erhält daraufhin die Flask Instanz ihre Daten bezüglich der Konfiguration für das Hosting. Damit diese Webserver Anwendung auch das Testing und die Continuous Integration unterstützt, wird hier das von der Dokumentation vorgegebene Muster für die Application Factory angewendet.

Bei Verfolgung dieses eben genannten Ansatzes wird eine Factory Funktion geschrieben, die neben der Kreierung einer Instanz die weitere Konfigurationen je nach Anwendungsfall erlaubt. Für den hauptsächlichen Verwendungszweck wird hier zunächst die Regelmaschine instanziert. Anschließend werden die Route Funktionalitäten deklariert [23]. Die Routes wiederum filtern die Anfragen nach den relevanten Daten, um diese an die Regelmaschinen-Instanz und ihren Funktionen weiterzugeben.

### 3.2.3 Syntax und Grammatik der Fakten und Regeln

Die relevanten Daten der Dokumente können nun durch den Extraktionsvorgang erhalten werden. Damit die Steuerung bzw. die Anfrage für die Datenextraktion den Benutzer:innen zugänglich gemacht wird, muss eine geeignete Syntax für die Regel- und Faktendefinition festgelegt werden.

Die Fakten werden deshalb zunächst als eine Menge der zu extrahierenden Objekte definiert. So wird eine Obermenge abgebildet, die als Hierarchie eine Teilmenge von Textfeldern, eine Teilmenge von konventionellen Tabellen, eine Teilmenge von unkonventionellen Tabellen und eine Teilmenge von benutzerdefinierten Tabellen besitzt. Die Teilmengen inkludieren jeweils auch die leere

Menge und besitzen als Elemente die Extraktionsziele, welche sich an der Namenskonvention vom Python Style Guide orientieren, und somit einen beliebigen Namen tragen können [42]. Für jedes Extraktionsobjekt gibt es benötigte und optionale Eigenschaften, denen Werte zugewiesen werden. Ein Fakt ist daher eine Wertezuweisung einer Eigenschaft eines Extraktionsziels.

Die Regeln werden neben den Fakten als weitere Obermenge definiert. Diese Menge lässt sich als eine Liste von Regeln darstellen, welche nach den selben Namenskonventionen der Fakten benannt werden. Als Element in der Regelmenge, besitzt jede Regel einen Regelausdruck, eine Regelaktion und eine Liste von Regelparametern, welche abhängig von der Regelaktion angegeben werden. Die Namen der Regelaktionen müssen dabei mit den Namen der gegebenen Funktionalitäten übereinstimmen, damit diese später von der Regelmaschine erkannt und mit den angegebenen Regelparametern ausgeführt werden können. Die Regelausdrücke werden als ein String angegeben und müssen zunächst syntaktisch verarbeitet werden. Hierfür existieren verschiedene Syntaxansätze.

Regelbasierte Systeme wie *CLIPS* nutzen, wie bereits beschrieben, eine angepasste Version der Syntax von der Programmiersprache Lisp. Diese Syntax bildet mit Hilfe von Schlüsselwörtern die Ausdrücke für Regeln und Fakten ab. Python ermöglicht Texte mittels der integrierten *eval()* Funktion zu evaluieren und falls es sich um eine Python Aussage handelt, diese auch auszuführen. Die Funktion *literal\_eval()* aus dem Python-Modul *Abstract Syntax Tree* (ast) erlaubt die selbe Funktionalität mit einer eingeschränkten Untermenge für die Python Ausdrücke. Hierbei werden bei beiden Funktionalitäten die Texteingaben mithilfe des Parsings in abstrakte Syntaxbäume abgebildet, die die daraus generierten Terminale und Operatoren beinhalten. Bibliotheken, wie die von Google entwickelte Software Common Expression Language (CEL) erlauben durch das Auswerten von Ausdrücken die Bildung einer Semantik [25]. Dafür wird eine Grammatik benutzt, die die Ausdrücke mit Hilfe von Regeln in ihre Typen und Namen als Bestandteile auflöst.

Das für dieses Projekt entwickelte regelbasierte System für die Komponente der symbolischen KI bedarf Regeln in Form von Booleschen Ausdrücken. Damit das regelbasierte System die Ausdrücke für die Regeln und Fakten gleicherweise auswerten kann, bedarf es eine für den Anwendungsfall angepasste Definition einer Grammatik. Hierfür wird die Parsing Bibliothek Lark benutzt, welches die Erstellung einer kontextfreien Grammatik in der Erweiterten Backus-Naur-Form (EBNF) erlaubt. Basierend auf dieser Bibliothek werden unter der Nutzung eines LALR-Parsers abstrakte Syntaxbäume aus Texteingaben generiert [27]. Im Listing 3.1 wird die implementierte Grammatik für das regelbasierte System als Rohstring dargestellt. Dieser wird dann dem Parser mitgegeben, womit jeglicher

```

1      rule_grammar = r"""
2      ?start: disjunction
3
4      ?disjunction: conjunction
5          | disjunction "or" conjunction -> or_
6
7      ?conjunction: expression
8          | conjunction "and" expression -> and_
9
10     ?expression: expression operator expression
11         | value
12
13     ?operator: comp_operator
14         | ident_operator -> ident_operator
15         | memb_operator -> memb_operator
16
17     ?comp_operator: "<" -> lt
18         | ">" -> gt
19         | "==" -> eq
20         | ">=" -> ge
21         | "<=" -> le
22         | "!=" -> ne
23
24     ?ident_operator: "is" -> is_
25         | "is" "not" -> is_not
26
27     ?memb_operator: "in" -> in_
28         | "not" "in" -> not_in
29
30     OBJECT_NAME: CNAME
31     PROPERTY_NAME: OBJECT_NAME ("." OBJECT_NAME | NUMBER) *
32     CHAR: /[\x27] . [\x27] /
33
34     ?value: PROPERTY_NAME -> property_name
35         | "True" -> true
36         | "False" -> false
37         | "null" -> null
38         | NUMBER -> number
39         | CHAR -> char
40         | ESCAPED_STRING -> string
41
42     %import common.CNAME
43     %import common.NUMBER
44     %import common.ESCAPED_STRING
45     %import common.WS
46     %ignore WS
47     """

```

Listing 3.1: kontextfreie Grammatik für die Regelevaluation

Regel- und Faktenausdruck durch einen abstrakten Syntaxbaum der Logik für die Evaluation dieser Regel bereitgestellt wird. Die booleschen Ausdrücken werden in der Syntax von Python genutzt, womit die Evaluation direkt stattfinden kann.

Der Aufbau der umgesetzten Grammatik basiert hierbei auf der klassischen Aussagenlogik und ihrer Definitionen[7]. Auf der Syntaxebene werden daher in EBNF die Produktionsregeln kleingeschrieben und die Terminalen großgeschrieben. Die Regel *start* wird zunächst als Startsymbol definiert. Von ihr lässt sich jedes Wort ableiten, welches die *disjunction* Regel erfüllt. Diese stellt eine aussagenlogische Oder-Verknüpfung beziehungsweise eine Disjunktion dar, welche wiederum aus der Regel für die Konjunktion oder für die Oder-Verknüpfung aus Disjunktion und Konjunktion ersetzt werden kann. Die Konjunktionsregel *conjunction* kann entweder durch die *expression* Regel ersetzt werden oder durch eine Und-Verknüpfung der *conjunction* Regel und der *expression* Regel. Die *expression* Regel stellt einen booleschen Ausdruck dar, welcher sich entweder mit der *value* Regel oder aus einer Kombination von einer *expression* Regel, von einer *operator* Regel und von einer weiteren *expression* Regel ableiten lässt.

```
text_areas.address_areas.page == 0 and conventional_tables.car_table.start_anchor == "Betrag"
or unconventional_tables.invoice_table.job_orientation != "last"
```

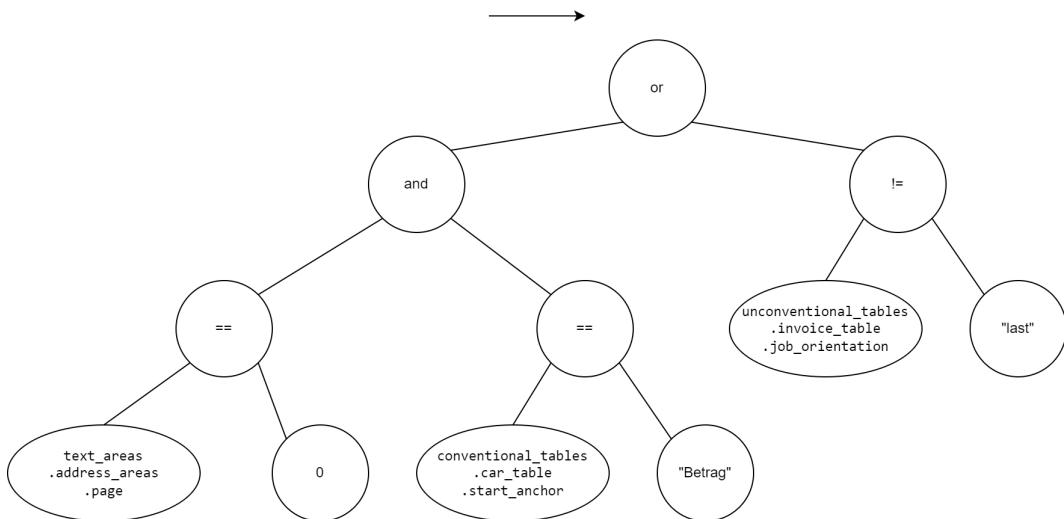


Abbildung 3.2: Generierter Syntaxbaum vom LALR-Parser

Bei der *value* Regel wird die Mehrdeutigkeit der Terminalen definiert, für die alle primitiven Datentypen abgedeckt werden. Die Terminalen *PROPERTY\_NAME* wird hier hervorgehoben, da diese den regulären Ausdruck einer Eigenschaft eines Extraktionsobjekts abbilden soll. Dabei ist dies als eine Verkettung durch

weitere Objektnamen durch die Punktnotation definiert. Für die *operator* Regel bestehen die Mehrdeutigkeiten aus der *comp\_operator* Regel, der *ident\_operator* Regel und der *memb\_operator* Regel, welche in der Reihenfolge aufgezählt die Vergleichsoperatoren, die Identitätsoperatoren und die Memberoperatoren abbilden. Arithmetische Operatoren, Zuweisungsoperatoren und bitweise Operatoren, die in Python existieren, werden für die aus der Grammatik erzeugten Sprache nicht definiert. Des Weiteren wird das Klammern für die Ausdrücke nicht unterstützt, weswegen die Operatorrangfolge durch die Produktionsregeln der Grammatik fest vorgegeben ist. Die restlichen Zeilen beinhalten die Importe der zusätzlichen Module für die Definition der Grammatik. Abbildung 3.2 zeigt ein Beispiel wie somit aus einem Regelausdruck ein Syntaxbaum durch den Parser kreiert werden kann. Mittels der Transformer Klasse der Lark-Bibliothek wird nämlich als Zwischenschritt die Syntax der einzelnen Blätter und Knoten des Baums so angepasst, dass diese für die weitere Verarbeitung beziehungsweise Evaluation der Regelmaschine bereitstehen.

### 3.2.4 Regelmaschine

Nachdem nun die Syntax und Grammatik der Regeln gegeben ist, wird die Regelmaschine als Modul entwickelt. Dieses Modul besteht aus den Klassen für den Regelinterpreter und den Regelspeicher. Während die Regelinterpreter Klasse die konkrete Logik der Vorwärtsverkettung beinhaltet, kümmert sich die Regelspeicher Klasse um das Bereitstellen und um die Speicherung der Regeln und Fakten.

Die Speicherung der Regeln und Fakten kann über den persistenten Ansatz der Datenbanken ermöglicht werden. Jedoch erlaubt der Ansatz der Speicherung der Regeln und Fakten über eine Datei im Dateisystem den schnellen Zugriff und die schnelle Bearbeitung jener. Des Weiteren kommt hier die Frage auf, in welchem Dateiformat die Regeln und Fakten festgehalten werden. Ein gängiges Serialisierungsformat wie JSON eignet sich durch ein festgelegtes Schema zur Speicherung, da die Daten strukturiert aufbewahrt werden. Demgegenüber existieren weitere Dateiformate, die eine geeignete Alternative darstellen.

Die Auszeichnungssprache YAML bildet die Obermenge zu JSON ab und ermöglicht neben den generischen Datentypen, die auch in JSON definiert sind, einen übersichtlicheren aber auch komplexeren Ansatz für ein Serialisierungsformat. Diese Sprache besitzt im Vergleich zu JSON eine bessere Lesbarkeit der Syntax, ist kompakter gestaltet und bietet eine hohe Kompatibilität zu dem JSON Format. [4]. Die Syntax für mögliche Kommentare ist obendrein auch verfügbar, wodurch sich diese Auszeichnungssprache für Konfigurationsdateien eignet, was

wiederum für die Definitionen der Regeln und Fakten abgebildet werden kann.

Die Serialisierungsformate unterscheiden sich letztendlich in der Zielsetzung: JSON wird für den leichten Datenaustausch für Webanwendungen aufgrund der leichten Serialisierung und Übersetzung mit dem Parser benutzt. YAML dagegen hat eine erhöhte Komplexität für die Serialisierung und Übersetzung, aber ist für Dateien gedacht, die von Menschen bearbeitet und damit genutzt werden sollen.

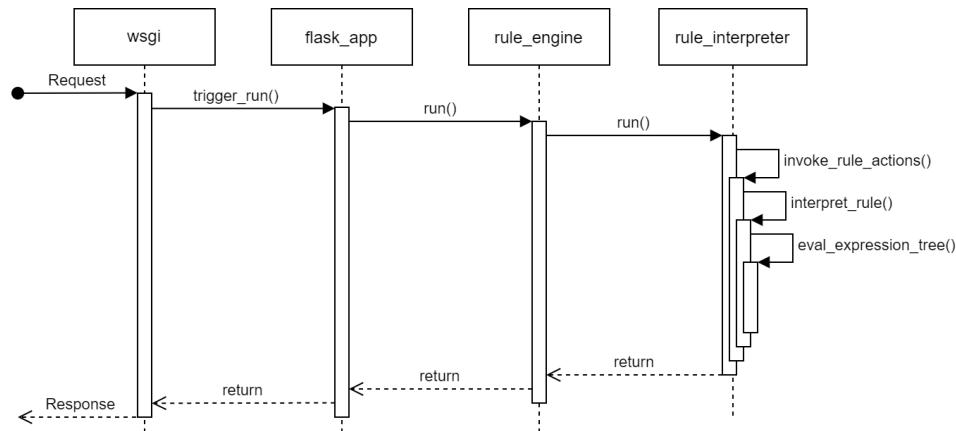


Abbildung 3.3: Durchlauf der Regelinterpretationen durch ein Request

Mit Hilfe einer Bibliothek für die Serialisierung und Übersetzung von YAML-Dateien werden ebendaher die Regeln und Fakten während der Laufzeit geladen, bearbeitet und gespeichert. Dabei wird sich für den Ansatz entschieden, die Regeln und Fakten für jede einzelne Dokumentenart zu speichern und zu verwenden. Während die booleschen Ausdrücke der Regeln als String dem Parser für die Grammatik übergeben werden, müssen aus den Fakten nach dem Laden während der Laufzeit eine für die Evaluation angepasste Version generiert werden. Hierfür werden durch eine Funktionalität die Fakten als eine Menge beziehungsweise als ein Dictionary erzeugt, die den Pfad zur Eigenschaft in der Punktnotation als Schlüssel besitzen, angegeben. Dies Konvertierung der Fakten ist für die Auswertung mit den Regeln im späteren Prozess geeignet.

Für den Ablauf wird, wie in Kapitel 3.2.2 beschrieben, zunächst die Regelmaschine beim Starten des Systems instanziert. Diese wiederum instanziert den Regelspeicher, welcher die Regeln und Fakten bereit hält, und den Regelinterpreter. Die Funktionalitäten des Interpreters werden dann aufgerufen, sobald die HTTP Anfrage bezüglich des Durchlaufens der Regelevaluation im WSGI ankommt. Die Abbildung 3.3 zeigt den Verlauf bei dieser Anfrage. So löst zunächst die Route-Anfrage die gekoppelte Funktion *trigger\_run()* der Flask Instanz aus,

welche wiederum die `run()` Methode der Regelmaschine auslöst. Diese ruft dann die `run()` Methode des Regelinterpreters mit der Angabe für welchen Dokumentart der Vorgang stattfinden soll auf. Dort werden iterativ die Regeln mit Hilfe der Funktion `invoke_rule_action()`

### **3.3 Entwicklungsumgebung**

Für die graphische Schnittstelle der Benutzer des Systems

#### **3.3.1 Editor**

#### **3.3.2 Dokumentenanzeige**

#### **3.3.3 Output**

### **3.4 Machine Learning**

Während

#### **3.4.1 Webserver**

#### **3.4.2 Pipeline**

## **Kapitel 4**

# **Ergebnisse**

### **4.1 Testing**

## **Kapitel 5**

# **Konklusion und Ausblick**

Im Rahmen der Abschlussarbeit wurde ein System konzipiert und umgesetzt, welches eine Extraktion von Dokumenten über zwei Ansätze ermöglicht. Über die Teilsysteme wurden technische Funktionalitäten eingeführt werden um dem Kapitän die Webanwendung als PWA anzubieten.

Insgesamt eignen sich Webanwendungen um Ressourcen übersichtlicher darzustellen und mobil zu beobachten. Auch können Offline-Zustände dem Benutzer trotzdem erlauben Aspekte der Anwendung weiter zu benutzen. Aus den Konzepten und der Umsetzung ergeben sich viele weitere Ideen und Ansätze, die realisierbar sind und implementiert werden können.

## Literaturverzeichnis

- [1] Milam W. Aiken and Olivia R. Liu Sheng. Nexpert object. *Expert Systems*, 7(1):54–57, 1990.
- [2] clips. CLIPS: A Tool for Building Expert Systems. <https://www.clipsrules.net/>.
- [3] David Embrey. The Skill, Rule and Knowledge Based Classification. *Human Error*, page 10.
- [4] Malin Eriksson and Victor Hallberg. Comparison between json and yaml for data serialization. *The School of Computer Science and Engineering Royal Institute of Technology*, pages 1–25, 2011.
- [5] Borko Furht, Esad Akar, and Whitney Angelica Andrews. *Creating User Interface*, pages 7–11. Springer International Publishing, Cham, 2018.
- [6] Miguel Grinberg. *Flask web development: developing web applications with python*. Ö'Reilly Media, Inc.", 2018.
- [7] Kevin C Klement. Propositional logic. 2004.
- [8] Di Liu, Tao Gu, and Jiang-Ping Xue. Rule Engine based on improvement Rete algorithm. In *The 2010 International Conference on Apperceiving Computing and Intelligence Analysis Proceeding*, pages 346–349, 2010.
- [9] Chris A. Mattmann and Jukka L. Zitting. *Tika in Action*. Manning Publications, Shelter Island, NY, 2012. Includes index.
- [10] Guido Van Rossum and Fred L. Drake. *Python 3 Reference Manual*. Create-Space, Scotts Valley, CA, 2009.
- [11] Sen Wu, Luke Hsiao, Xiao Cheng, Braden Hancock, Theodoros Rekatsinas, Philip Levis, and Christopher Ré. Fonduer: Knowledge base construction from richly formatted data. In *Proceedings of the 2018 International Conference on Management of Data*, pages 1301–1316. ACM, 2018.
- [12] Zhi-Hua Zhou. A brief introduction to weakly supervised learning. *National Science Review*, 5(1):44–53, August 2017.

## Online-Quellen

- [13] Bedeutung AW (Arbeitswert). <https://wissen.autoxpert.de/hc/de/articles/360008973819-Bedeutung-AW-Arbeitswert->.

- [14] abbyy. PDF Software: Open, Read & Edit PDFs. <https://pdf.abbyy.com/>. [letzter Zugriff: 4. Juni 2022].
- [15] amazon. Intelligente Extraktion von Text und Daten mit OCR – Amazon Textract – Amazon Web Services. <https://aws.amazon.com/de/textract/>. [letzter Zugriff: 4. Juni 2022].
- [16] apache. Apache Tika – Apache Tika. <https://tika.apache.org/>. [letzter Zugriff: 4. Juni 2022].
- [17] atlanhq. Comparison with other PDF Table Extraction libraries and tools · atlanhq/camelot Wiki. <https://github.com/atlanhq/camelot>. [letzter Zugriff: 4. Juni 2022].
- [18] camelot. Camelot: PDF Table Extraction for Humans. Atlan Technologies Pvt Ltd, July 2022. [letzter Zugriff: 4. Juni 2022].
- [19] Adobe I/O-Adobe Developers. Extract Text from PDF | Extract Data from PDF | Visualizer - Adobe Developers. <https://developer.adobe.com/document-services/apis/pdf-extract/>. [letzter Zugriff: 4. Juni 2022].
- [20] Ben Dickson. What is symbolic artificial intelligence? <https://bdtechtalks.com/2019/11/18/what-is-symbolic-artificial-intelligence/>, November 2019. [letzter Zugriff: 4. Juni 2022].
- [21] Docsumo. PDF Scraper - Scrape data from pdf | PDF data extraction. <https://docsumo.com/blog/extract-data-from-pdf>, June 2022. [letzter Zugriff: 4. Juni 2022].
- [22] explosion. spaCy · Industrial-strength Natural Language Processing in Python. <https://spacy.io/>.
- [23] flask. API — Flask Documentation (2.1.x). <https://flask.palletsprojects.com/en/2.1.x/api/#url-route-registrations>.
- [24] Bruce Frederiksen. Welcome to Pyke. <http://pyke.sourceforge.net/index.html>.
- [25] Google. Common Expression Language. <https://chromium.googlesource.com/external/github.com/google/cel-go/+/refs/tags/v0.9.0/README.md>.
- [26] Paul Haleyai. Haley / ART syntax lives on in open-source Java rules – Commercial Intelligence, 2008.

- [27] lark-parser. Lark-parser/lark: Lark is a parsing toolkit for Python, built with a focus on ergonomics, performance and modularity. <https://github.com/lark-parser/lark>.
- [28] measures. Measuresforjustice/textricator: Textricator is a tool to extract text from documents and generate structured data. <https://github.com/measuresforjustice/textricator>. [letzter Zugriff: 4. Juni 2022].
- [29] omar. Dear ImGui, July 2022.
- [30] pdfminer. Welcome to pdfminer.six's documentation! — pdfminer.six \_\_VERSION\_\_ documentation. <https://pdfminersix.readthedocs.io/en/latest/>.
- [31] Roberto Abdelkader Martínez Pérez. Nilp0inter/experta, July 2022.
- [32] pyTorch. PyTorch. <https://www.pytorch.org>.
- [33] qt. Qt | Cross-platform software development for embedded & desktop. <https://www.qt.io>.
- [34] Jesus Ruiz. Durable\_rules, March 2022. [letzter Zugriff: 4. Juni 2022].
- [35] Jeremy Singer-Vine. Pdfplumber, July 2022.
- [36] stichdata. What is Data Extraction? [ Tools & Techniques ]. <https://www.stitchdata.com/what-is-data-extraction/>. [letzter Zugriff: 4. Juni 2022].
- [37] svelte. Svelte • Cybernetically enhanced web apps. <https://svelte.dev/>.
- [38] tabulapdf. Tabulapdf/tabula: Tabula is a tool for liberating data tables trapped inside PDF files. <https://github.com/tabulapdf/tabula>. [letzter Zugriff: 4. Juni 2022].
- [39] tensorflow. TensorFlow. <https://www.tensorflow.org/?hl=de>.
- [40] Laura Theuerer. Was macht das After Sales Management im Autohaus? | Karriere-Ratgeber - kfz-betrieb Jobs. <https://jobs.kfz-betrieb.de/karriere-ratgeber/was-macht-das-after-sales-management-im-autohaus-51.html>. [letzter Zugriff: 4. Juni 2022].
- [41] unixuser. PDFMiner. <https://www.unixuser.org/~euske/python/pdfminer/>. [letzter Zugriff: 4. Juni 2022].
- [42] Guido van Rossum, Barry Warsaw, and Nick Coghlan. Style guide for Python code. PEP 8, 2001.